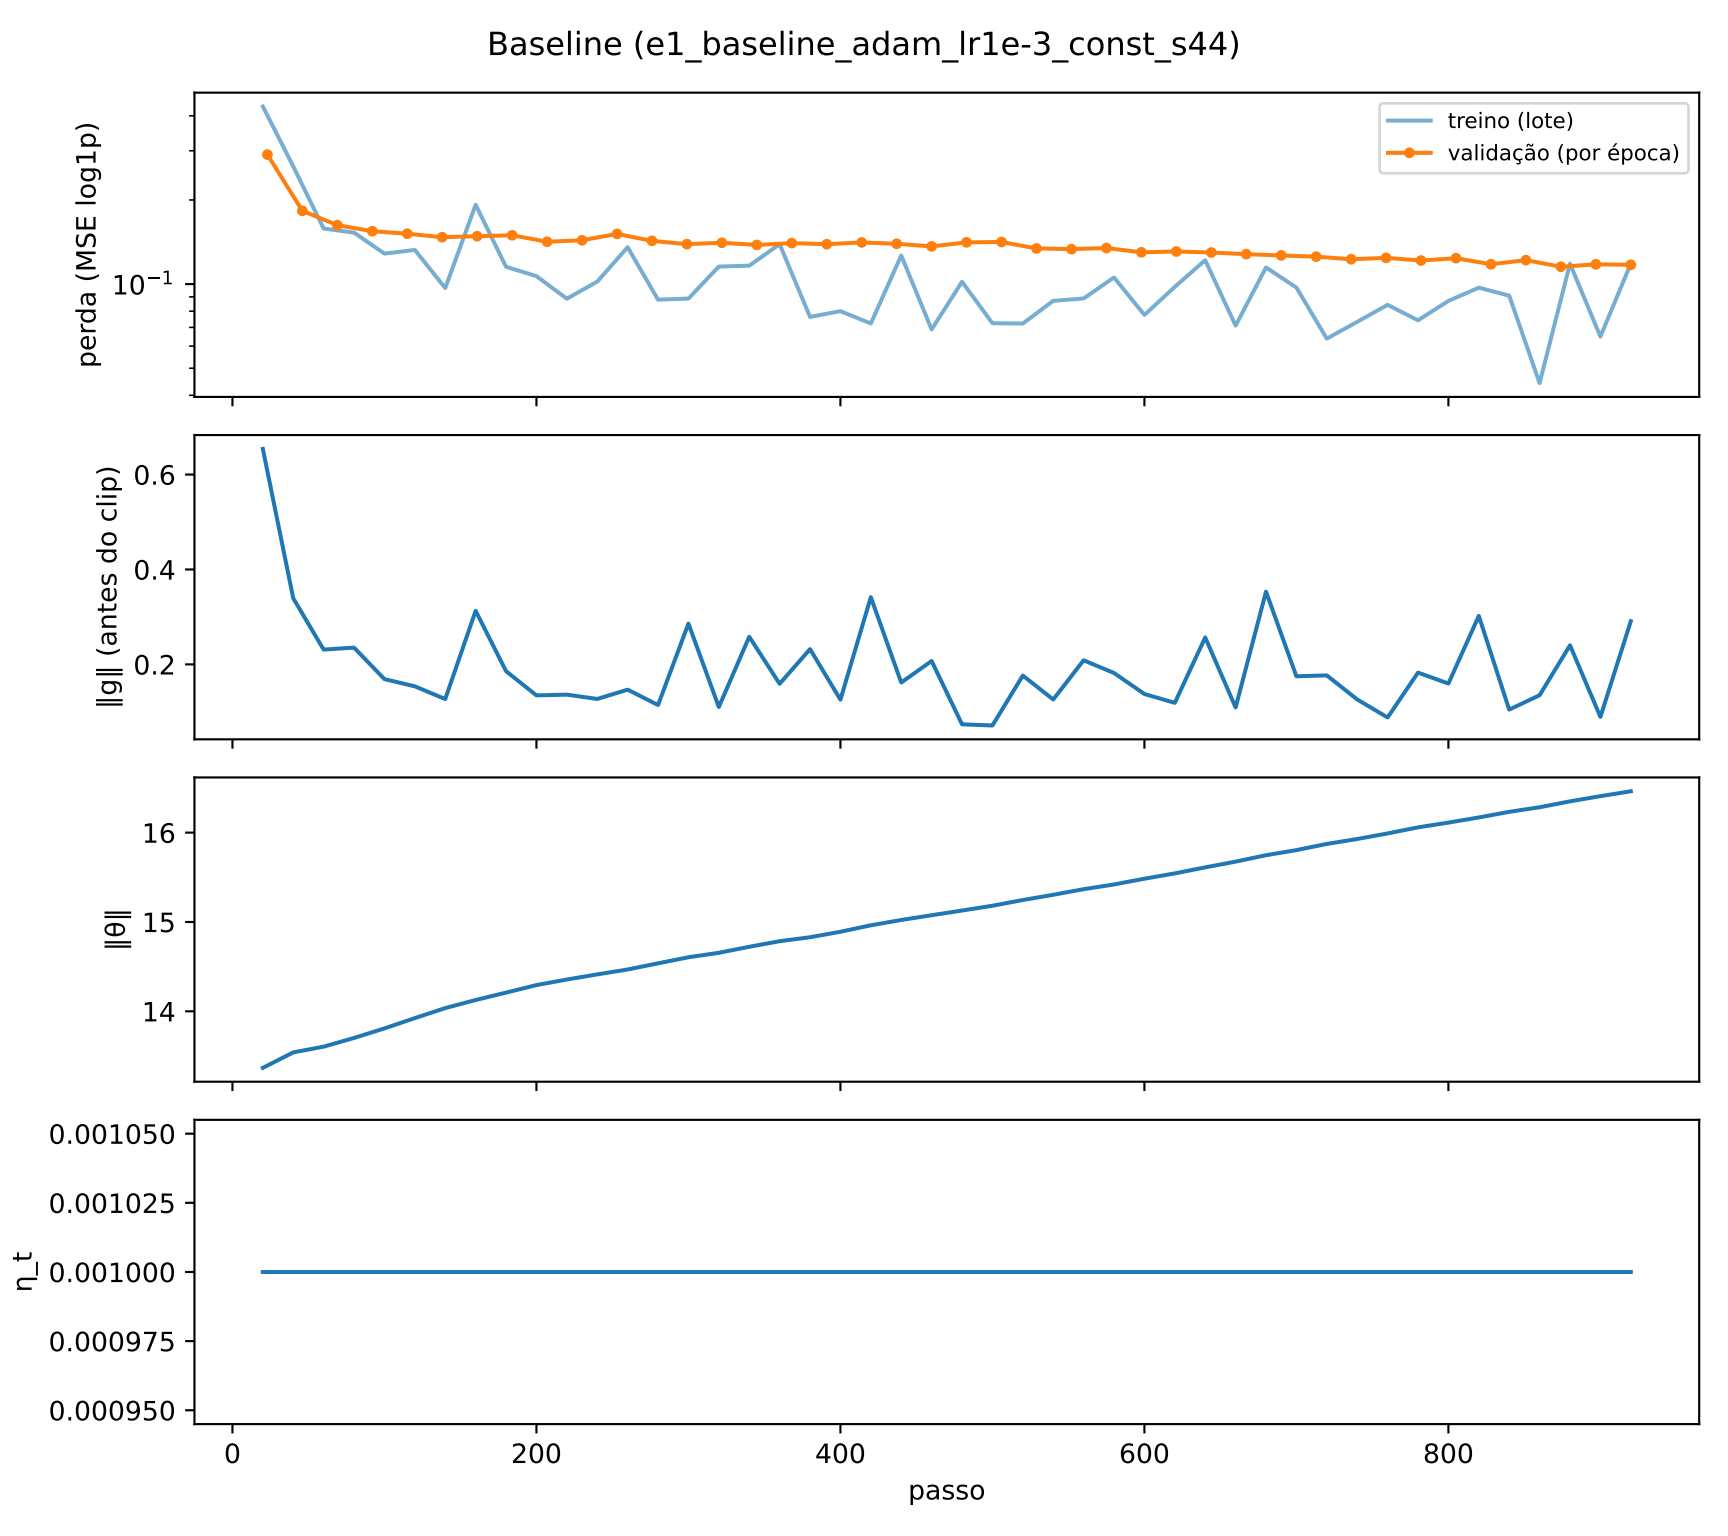
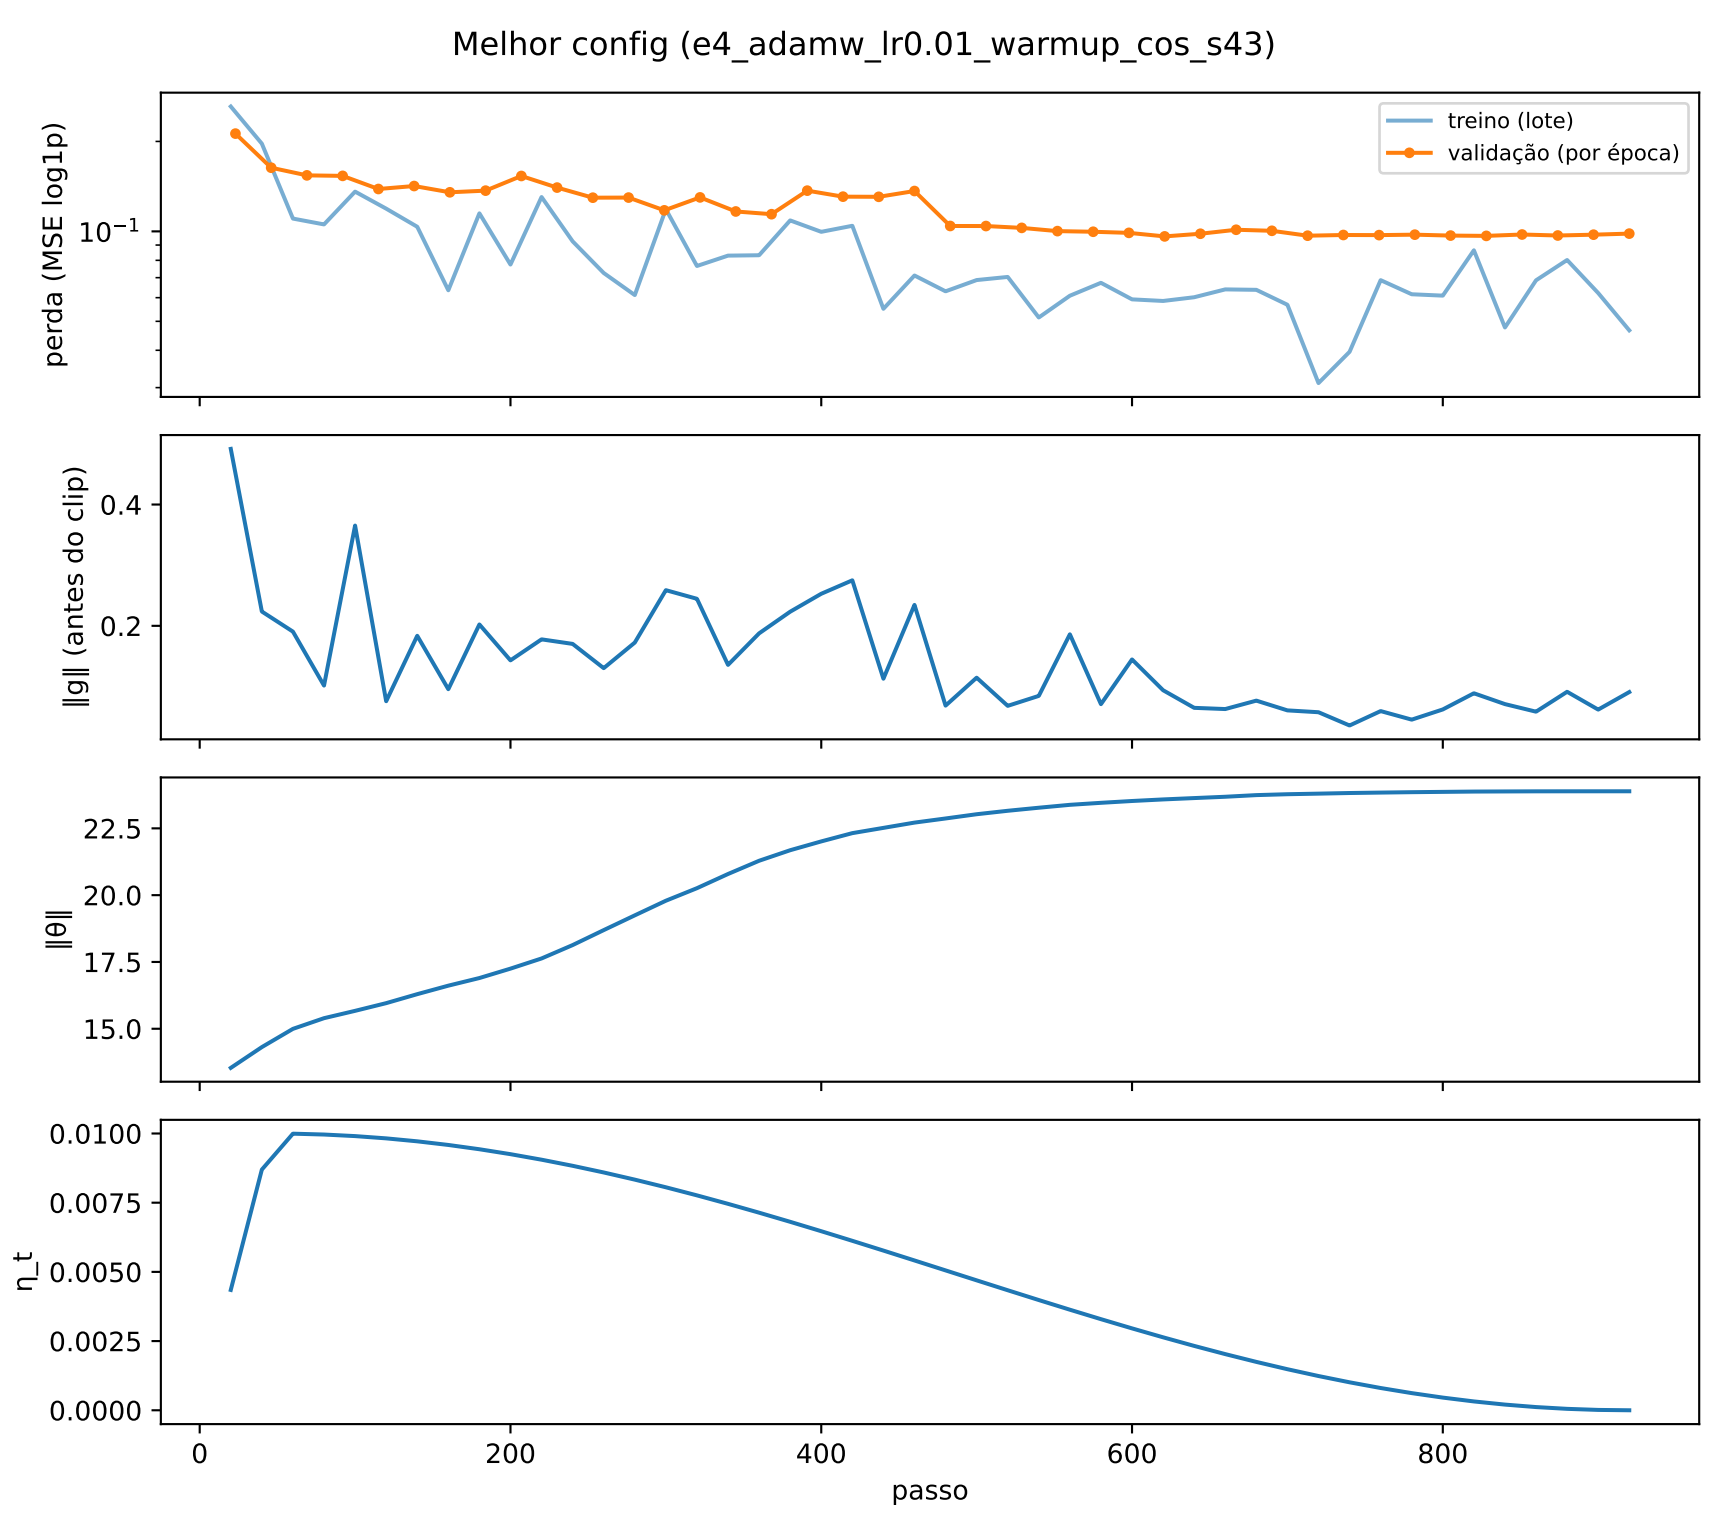
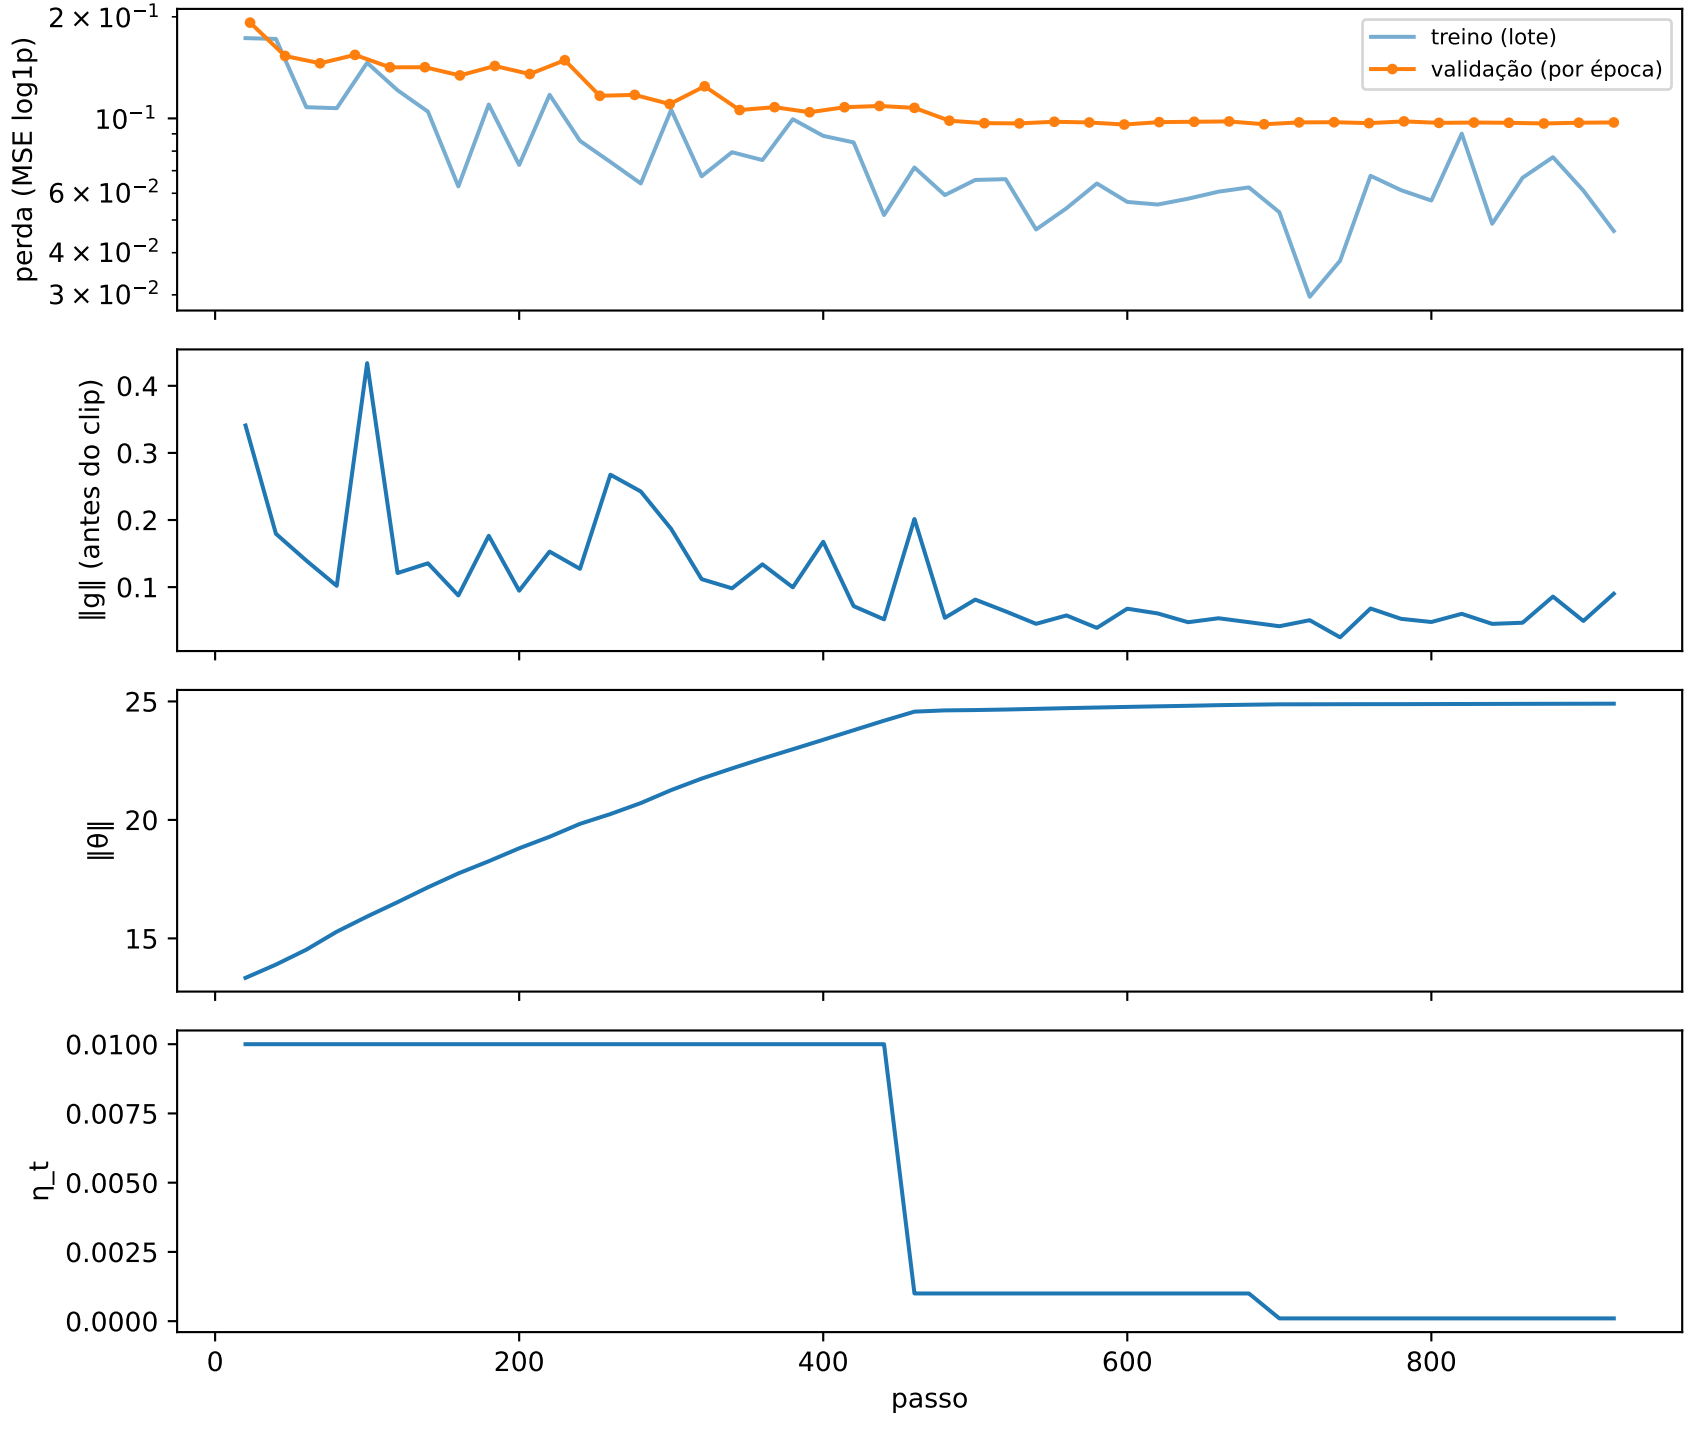
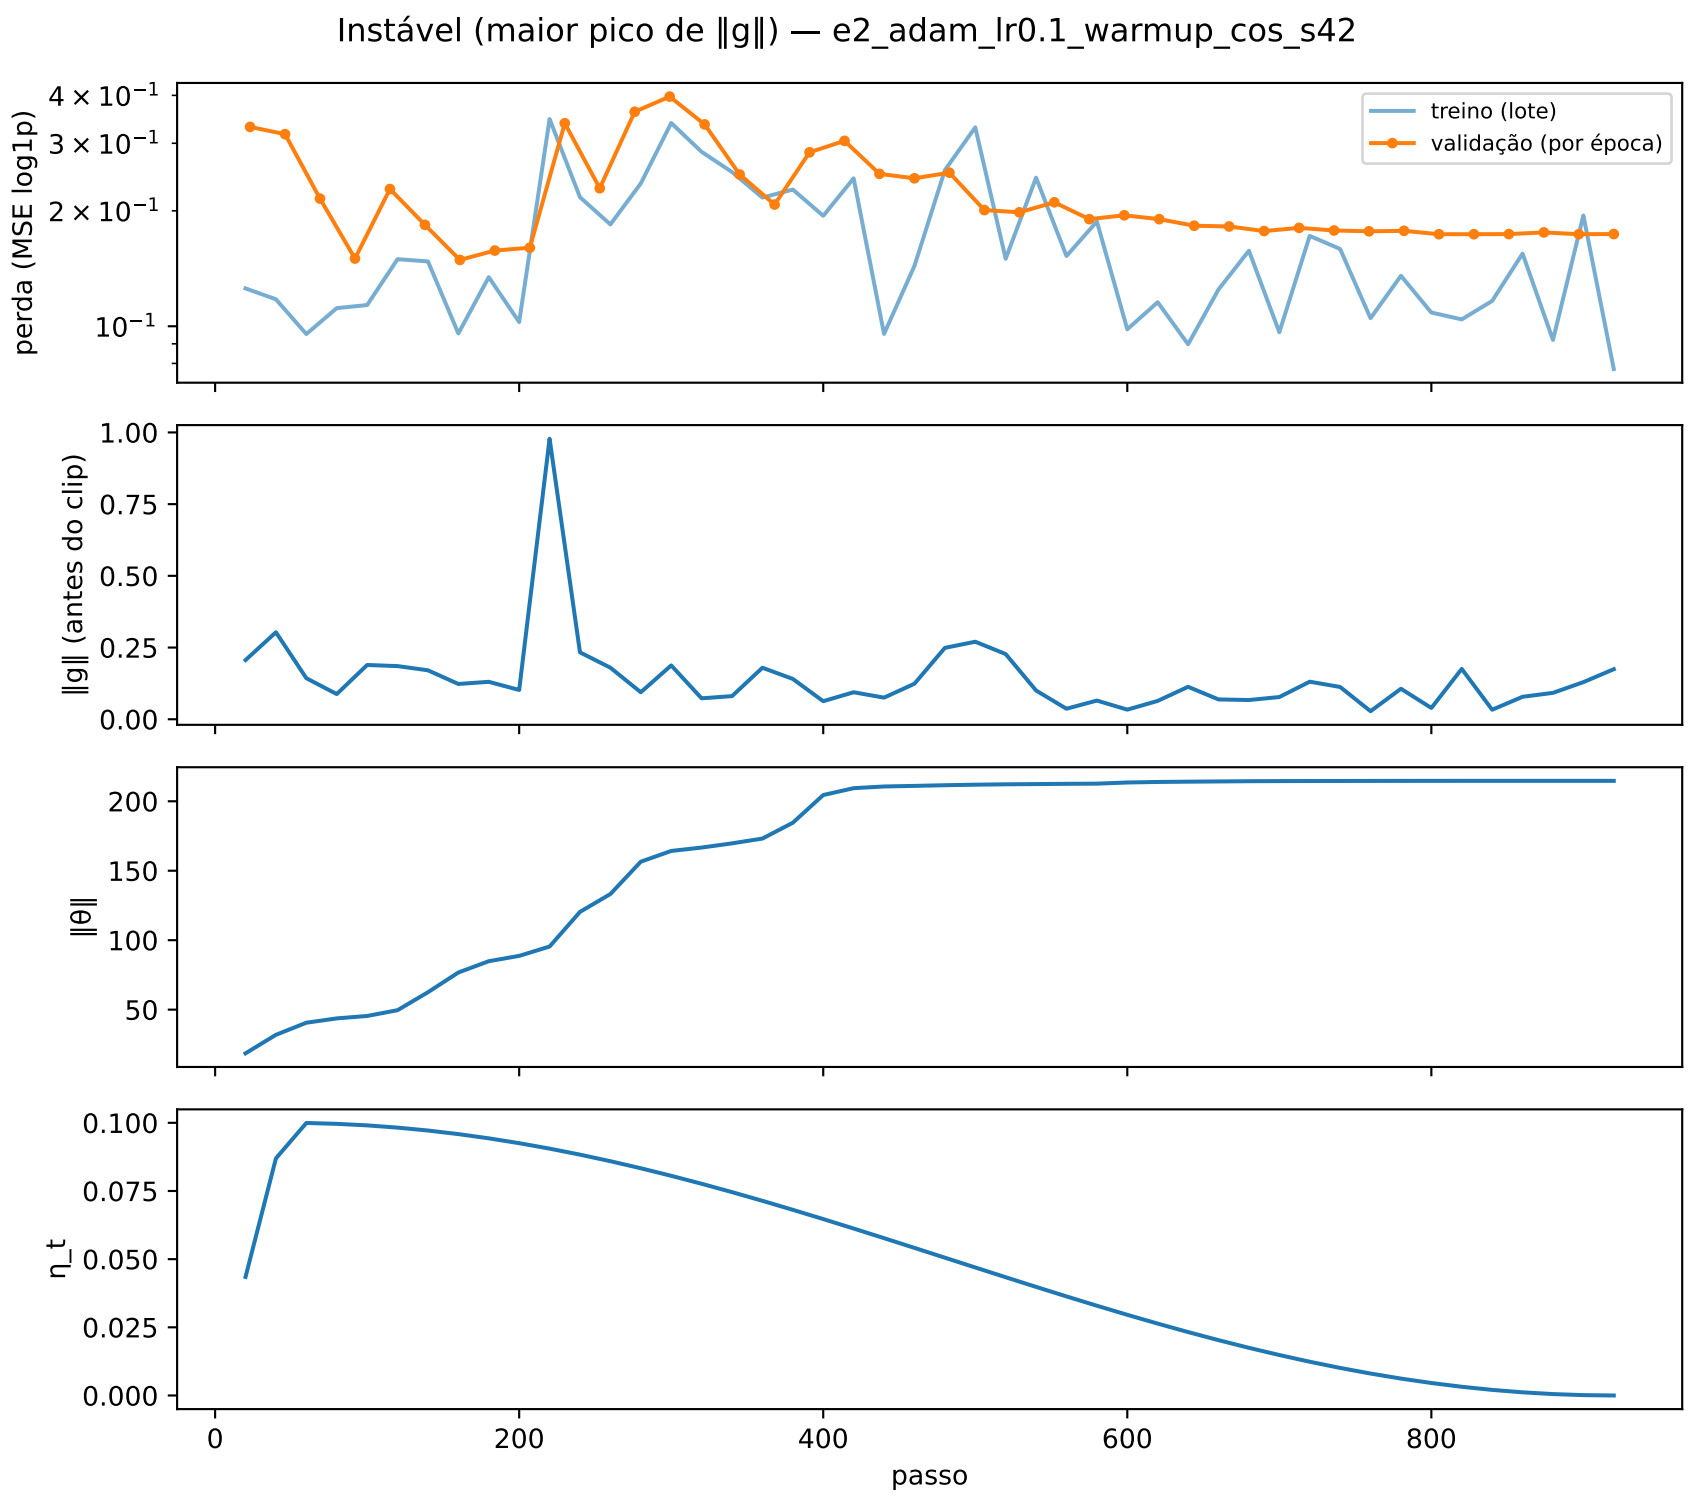
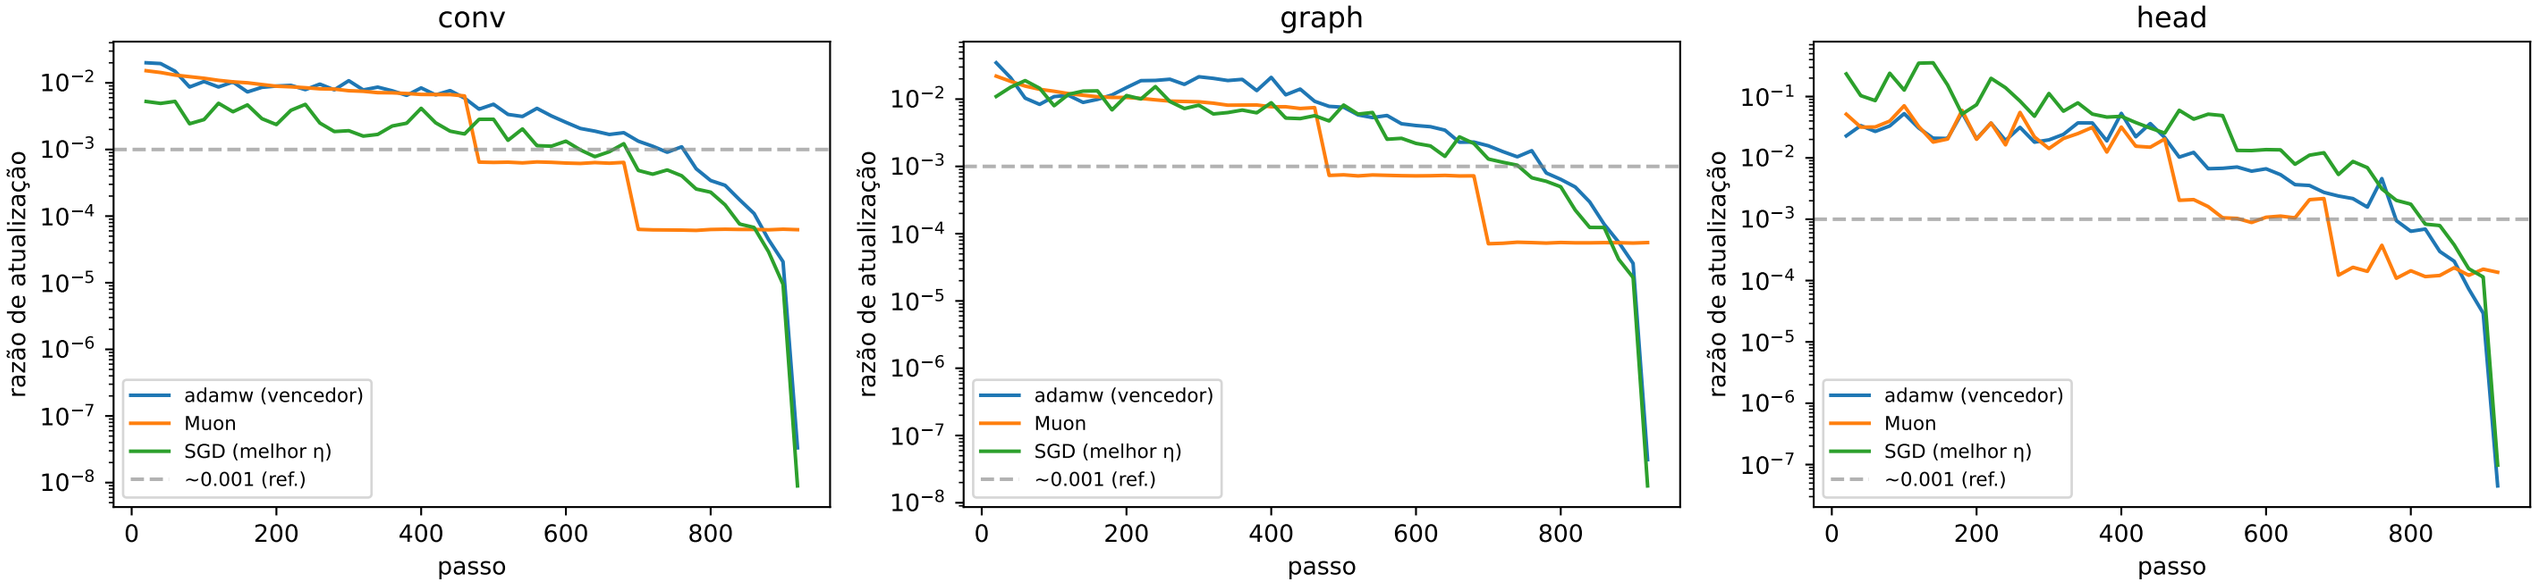
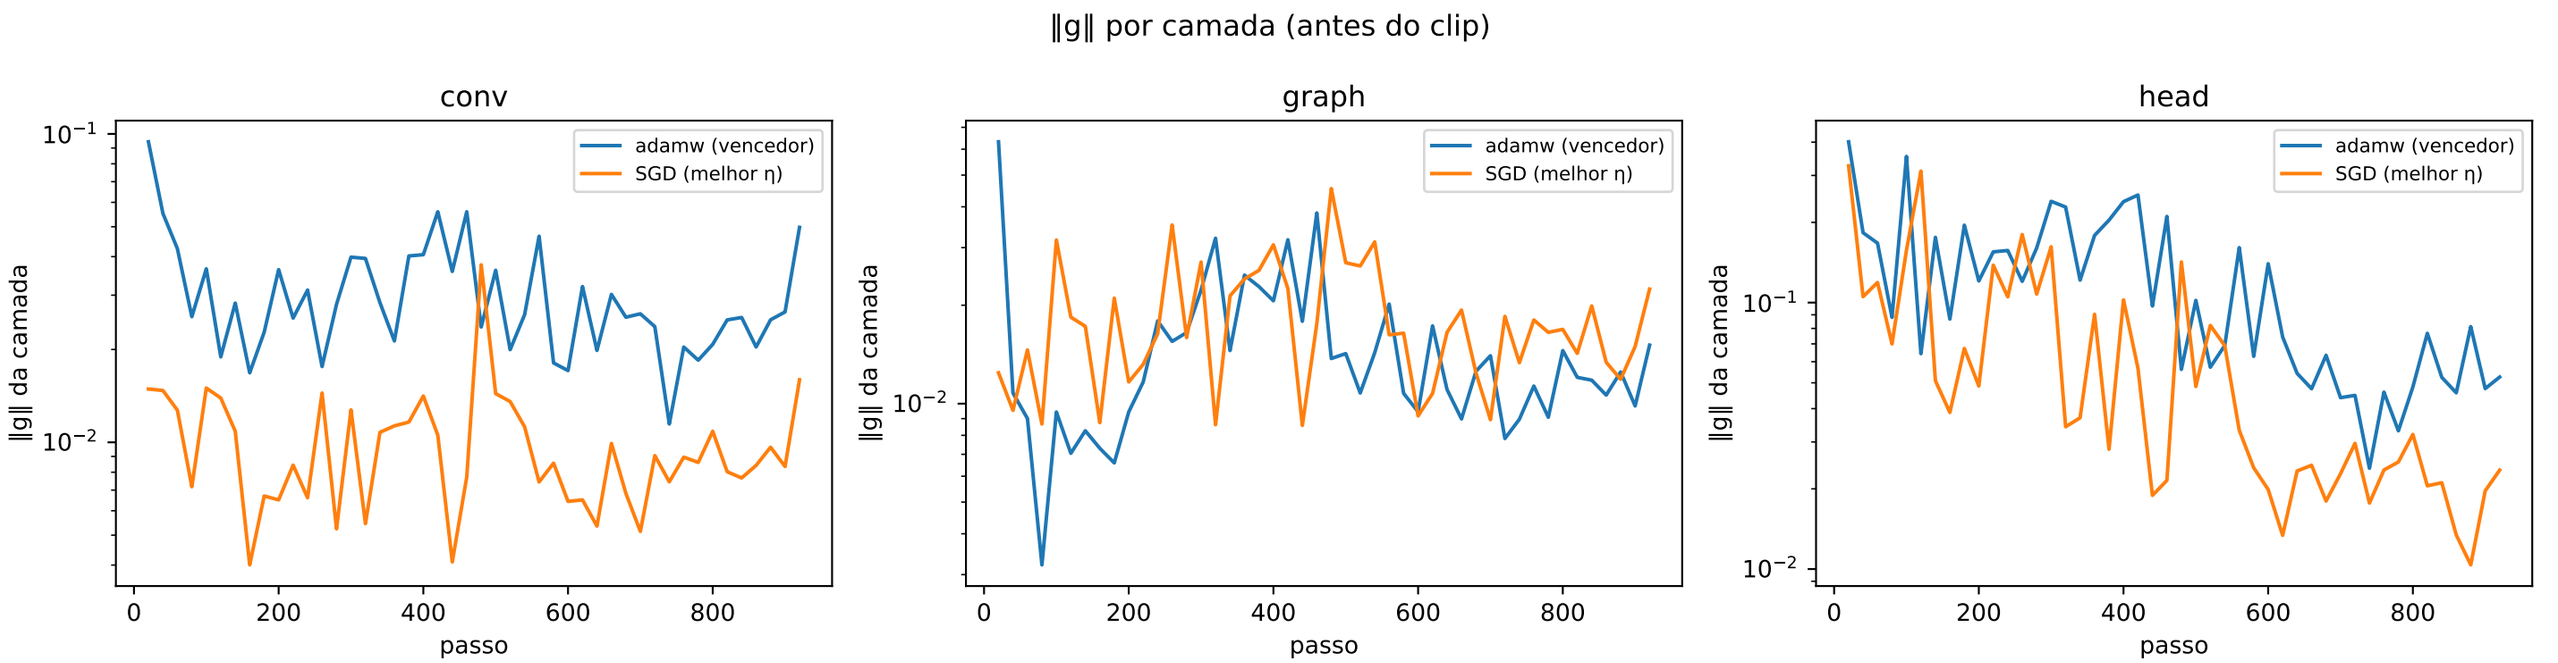

Baseline (e1_baseline_adam_lr1e-3_const_s44)
perda (MSE log1p)
10^{-1}
treino (lote)
validação (por época)
‖g‖ (antes do clip)
0.6
0.4
0.2
‖θ‖
16
15
14
η_t
0.001050
0.001025
0.001000
0.000975
0.000950
0
200
400
600
800
passo

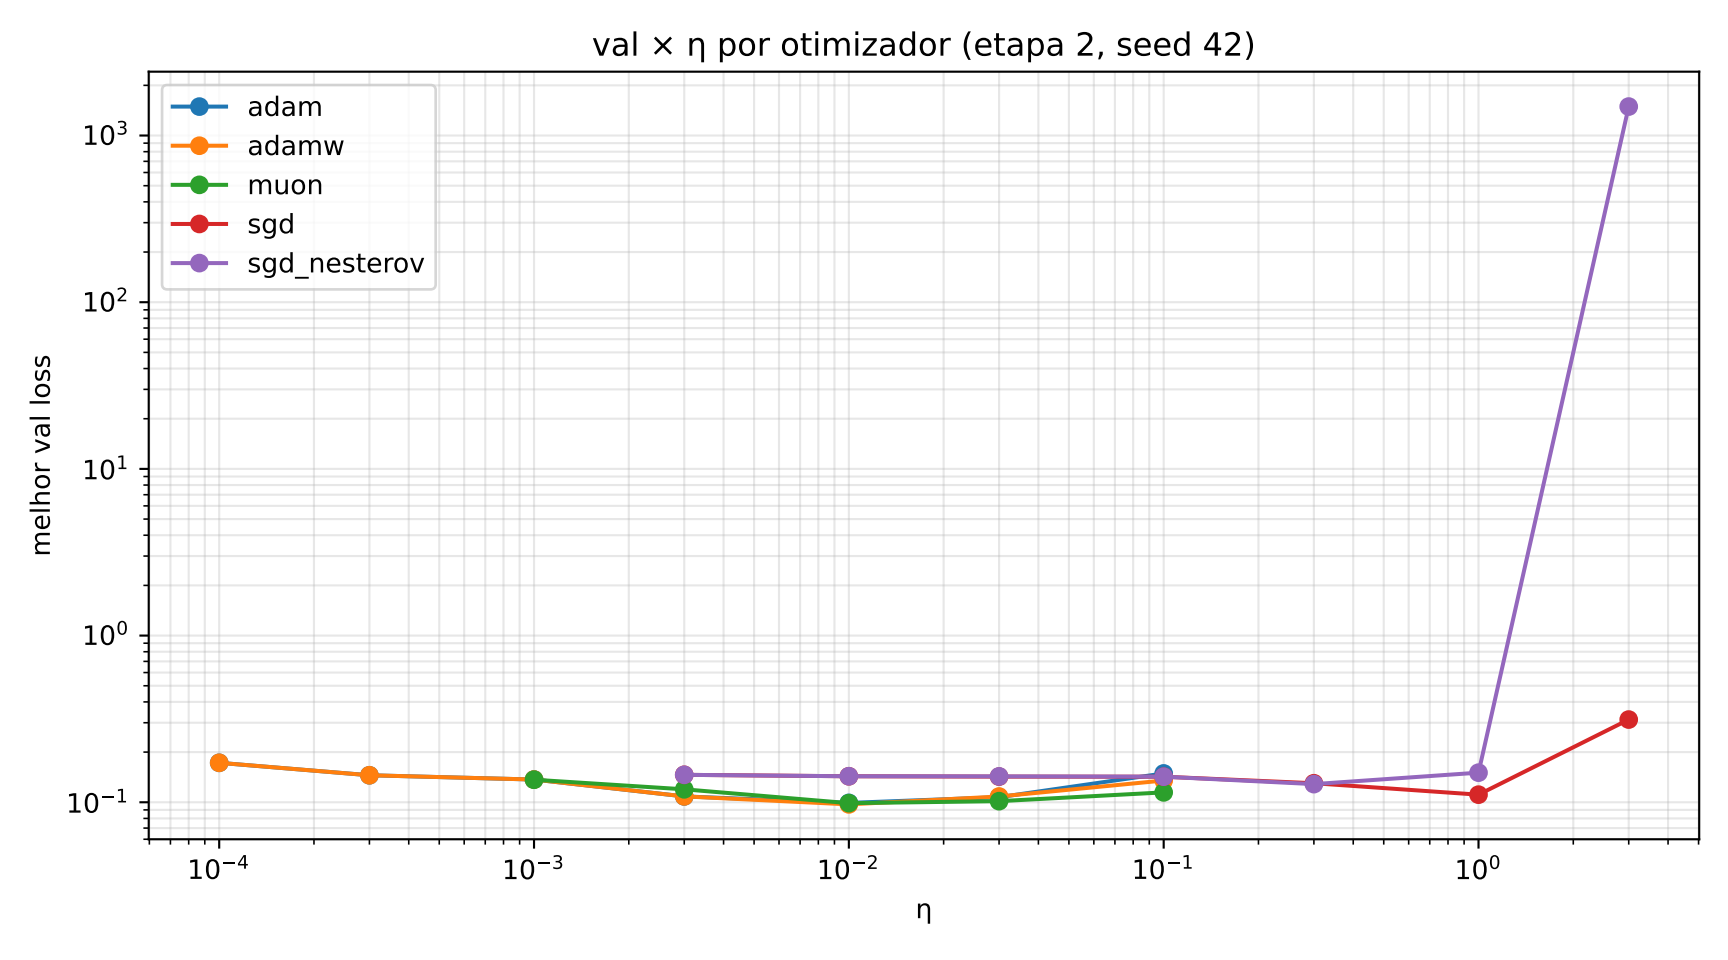

Melhor config (e4_adamw_lr0.01_warmup_cos_s43)
perda (MSE log1p)
10^{-1}
treino (lote)
validação (por época)
‖g‖ (antes do clip)
0.4
0.2
‖θ‖
22.5
20.0
17.5
15.0
η_t
0.0100
0.0075
0.0050
0.0025
0.0000
0
200
400
600
800
passo


Melhor com Muon (e4_muon_lr0.01_multistep_s43)
perda (MSE log1p)
treino (lote)
validação (por época)
‖g‖ (antes do clip)
‖θ‖
η_t
passo


Instável (maior pico de ‖g‖) — e2_adam_lr0.1_warmup_cos_s42
perda (MSE log1p)
treino (lote)
validação (por época)
‖g‖ (antes do clip)
‖θ‖
η_t
passo


Razão de atualização por camada
conv
graph
head
razão de atualização
passo
adamw (vencedor)
Muon
SGD (melhor η)
~0.001 (ref.)


‖g‖ por camada (antes do clip)
conv
graph
head
adamw (vencedor)
SGD (melhor η)
‖g‖ da camada
passo
10^{-1}
10^{-2}
0
200
400
600
800


val × η por otimizador (etapa 2, seed 42)
adam
adamw
muon
sgd
sgd_nesterov
melhor val loss
10^{3}
10^{2}
10^{1}
10^{0}
10^{-1}
10^{-4}
10^{-3}
10^{-2}
10^{-1}
10^{0}
η