Prever internações por dengue nos municípios do RJ

Autores · Gabriel Amorim · Gabriel Moutinho

O problema

- Prever a taxa semanal de internações por dengue em 79 municípios do RJ
- Entrada: 4 semanas passadas. Saída: as 4 semanas seguintes
- Dados: 1999 a 2021, 1.199 semanas por município (Zenodo)
- 77,8% dos valores são zero

12 variáveis de entrada

- Internações passadas (em log1p)
- Clima: temperatura, chuva, umidade
- Emissões: CO_2, CH_4, NO_2
- Densidade, pobreza, urbanização
- Clima defasado: temperatura de 13 semanas atrás e chuva de 15 (ciclo do mosquito)

Treino, validação e teste



Treino 1999–2012: 716 janelas

Validação 2013–2015: 156 janelas

Teste 2016–2021: 312 janelas

Ordem cronológica, o futuro não vaza para o treino.

Função de perda

MSE (Erro Quadrático Médio) calculado diretamente sobre os dados transformados em log1p;
Treino e validação usam o log da taxa, ln(1+y): o log comprime os picos e o +1 mantém o zero. No teste voltamos à escala real para medir o erro com base nos valores do dataset.

O que fizemos: modelo e protocolo

Rede espaço-temporal em grafo (STGCN), 27.876 parâmetros

Modelo

Entrada [32, 79, 4, 12]: lote, municípios, semanas, canais

2 blocos de 32 canais, com BatchNorm e Dropout 0,2.

6 Camadas: conv temporal GLU → conv em grafo → conv temporal GLU

Camada final: linear 32 canais → 4 previsões. Saída [32, 79, 4]: previsão das semanas t+1 a t+4

Testes dos Otimizadores:

5 otimizadores; Orçamento Fixo e Sem Early Stopping; Baseline (Adam com η à 0,001); Varredura de Taxa de Aprendizado (Grade de 5 Valores e regra da borda);

Muon: como dividimos os parâmetros

Muon: 27.264 parâmetros (97,8%), os kernels das convoluções e o θ do grafo, achatados em matrizes.
AdamW: 612 parâmetros, vieses, BatchNorm e camada final.
Mesma agenda nos dois.

Os 5 otimizadores (melhor val loss)

Otimizador	Como funciona	Val loss
AdamW	adapta o passo por parâmetro e isola o decaimento do erro;	0,0971
Muon	ortogonaliza o momento das matrizes, olha todas direções e ajuda a avaliar padrões mais raros;	0,0988
Adam	passo adaptado a cada parâmetro;	0,0991
SGD	aplica um único passo para todos os pesos da rede;	0,1111
SGD+Nesterov	SGD com momento que olha adiante para antecipar correções;	0,1285

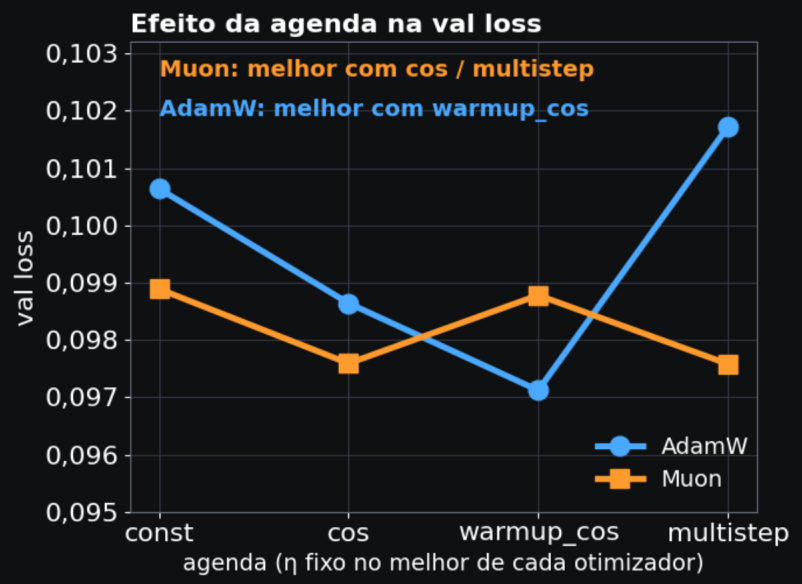
Arquitetura STGCN

Criada para prever tráfego (Yu et al., 2018) e adaptada para dengue (Siabi et al., 2026).

Melhores otimizadores: AdamW × Muon

Protocolo: 59 treinos de 920 passos

3 otimizadores, η por otimizador · 4 agendas. As 3 melhores combinações × 3 sementes. Escolha pela validação; teste lido uma vez.



Diferença entre melhor e pior dos 2 otimizadores: AdamW 0,0046 · Muon 0,0013

	Baseline	AdamW (vencedor)	Muon
Atualização	passo por parâmetro (Adam)	passo por parâmetro, decaimento desacoplado	ortogonaliza o momento das matrizes
η · agenda	0,001 · constante	0,01 · warmup_cos	0,01 · multistep
Val loss (3 sementes)	**0,1161 ± 0,0009**	**0,0967 ± 0,0005**	**0,0975 ± 0,0015**
Leitura	**ponto de comparação**	**ganho de 0,0194 em relação ao baseline**	**empate técnico com o AdamW**

Empates

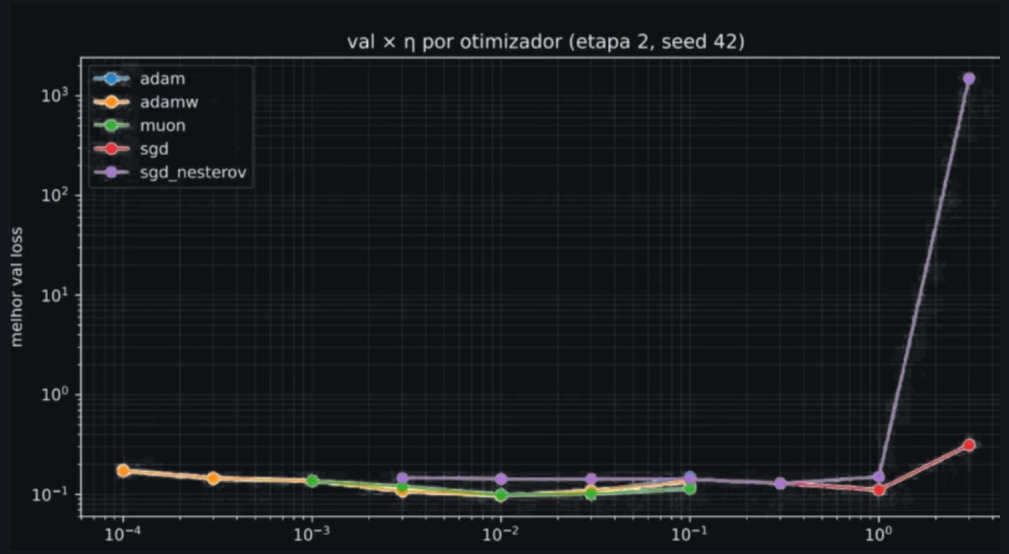
Muon × AdamW: diferença de 0,0008, menor que a oscilação do Muon (± 0,0015). Muon cos × multistep: diferença de 0,0001.

Diagnóstico nos sinais

O passo (η_t) começa pequeno, sobe e depois diminui até zero; conforme diminui, o erro de validação estabiliza. Na baseline, com passo pequeno e fixo (0,001), o erro ainda caía quando o treino acabou.

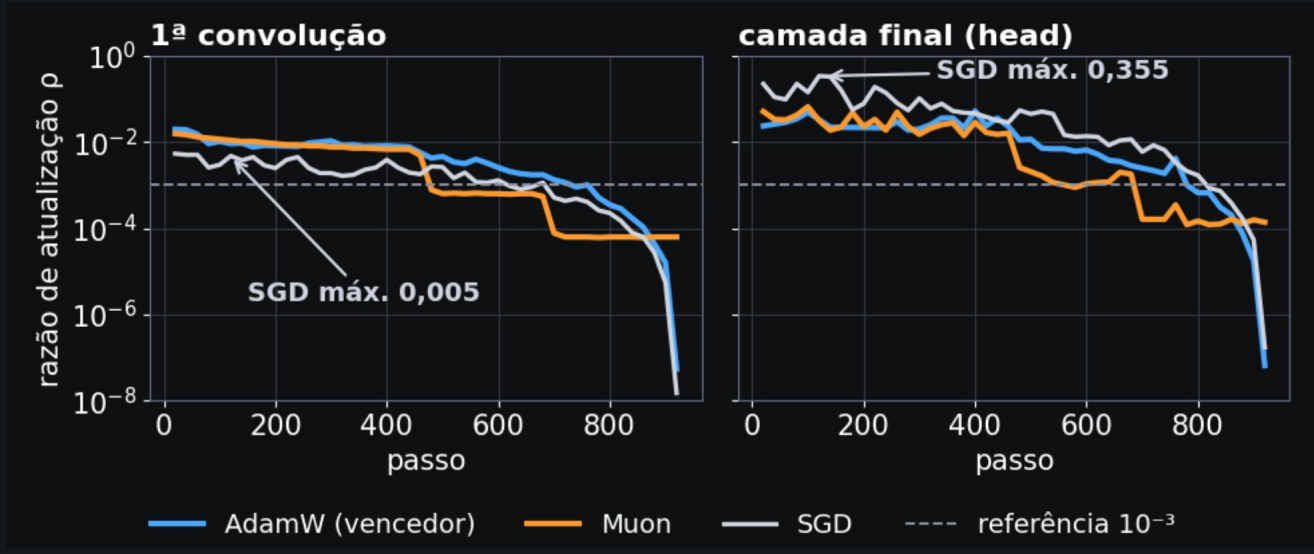
Avaliação dos Sinais

O Muon e AdamW já haviam apresentado resultados superiores, conforme slide anterior. Porém, para reforçar nosso achado e o porque de escolhermos os dois, os gráficos abaixo explicitam a diferença entre eles, considerando os outros otimizadores:



Melhor val loss para cada η (etapa 2, semente 42), eixos em escala log.

Adam, AdamW e Muon têm o mínimo perto de η = 0,01. O SGD precisa de η = 1, e o Nesterov dispara em η = 3. Um único η não serve para todos.



Razão de atualização (tamanho do passo ÷ tamanho do peso) por passo de treino: 1ª convolução (esquerda) e camada final (direita).

SGD aplica um único passo para toda a rede e se mostrou instável entre as camadas. Primeira camada fica muito baixa (base mal aprende) e na camada final sobe consideravelmente.